

TUẦN 1

I. Linear Regression

1. Tham số và Loss Function (Hàm mất mát)

- **Tham số (Weights - w và Bias - b):** khi dữ liệu đầu vào là cố định, mô hình sẽ liên tục thay đổi w và b để tìm ra con số sao cho mô hình tương đồng nhất, loss function thấp
- **Mục đích của Loss Function:** Hàm loss dùng để đo "sai" so với thực tế bao nhiêu. Đầu vào của hàm loss là kết quả dự đoán ($y^{\wedge}$) và giá trị thực tế (y), đầu ra là một giá trị vô hướng biểu thị mức độ sai số.

2. Bản chất Toán học của hàm MSE

- **Tại sao lại dùng bình phương?** Hàm bậc 2 được chọn vì nó có tính lồi, đảm bảo mọi thuật toán tối ưu sẽ tìm được đáy vì khi đạo hàm, sẽ có đạo hàm ở khắp nơi, đồng thời khi giải đạo hàm = 0, mô hình luôn tìm được GTNN. Không dùng bậc 3 vì đồ thị hàm bậc 3 có gtnn và gtlđ cục bộ -> nghĩa là mô hình sẽ không bao giờ tìm được GTNN toàn cục để mô hình có tương đồng nhất. Không dùng bậc 4 vì đạo hàm của nó sẽ là bậc 3, dẫn đến kết quả cũng là GTNN và GTLN cục bộ -> mục tiêu chính của Loss function là tìm ra GTNN sao cho tại đó loss function không thể nhỏ hơn được -> vì vậy bậc 2 sẽ là tối ưu nhất
- **Hệ số $1/n$ và $1/2n$:** Thành phần $1/n$ giúp tính trung bình sai số, làm cho hàm loss không bị lớn khi số lượng dữ liệu lớn. Hệ số $1/2n$ là một thủ thuật toán học: khi đạo hàm của bình phương sinh ra số 2, nó sẽ triệt tiêu với $1/2$, giúp công thức đẹp hơn. Các hằng số này chỉ làm giãn đồ thị chứ không làm thay đổi vị trí của điểm cực tiểu -> giống với $2f(x)$ và $f(x)$ thực chất về

nội dung sẽ là gấp đôi. Nhưng hình thức và bản chất thì chúng như nhau -> hoặc đơn giản hơn là, nếu $f(x)$ mà bé nhất -> $2f(x)$ cũng sẽ bé nhất, chỉ là biểu diễn trên hệ số nhân 2. Vì vậy $\frac{1}{2}$ hay $\frac{1}{n}$ đều không ảnh hưởng đến kết quả cuối cùng.

3. Gradient Descent và Hàm Lỗi (Convex Optimization)

- **Gradient Descent:** Là thuật toán tìm đáy. Đạo hàm chỉ ra "hướng dốc nhất" tại một điểm. Sau mỗi vòng lặp, thuật toán đi ngược hướng đạo hàm để cập nhật w, b , đó chính là quá trình "học" của mô hình -> Cụ thể ở đạo hàm của MSE, khi ta lấy Xw trừ đi y thực tế, Xw đại diện cho y dự đoán -> nếu y dự đoán càng gần y thực tế thì kết quả gần tiến về 0 -> mô hình sẽ đi dần dần về đáy tức đạo hàm của mse sẽ gần bằng 0.
- Thực chất hàm lỗi chính là hàm parabol (nghĩa là đạo hàm MSE chính là hàm lỗi)

4. Đặc điểm Đầu vào/Đầu ra và ý nghĩa "Linear"

- **Đầu vào/Đầu ra:** Đầu vào là ma trận X (dữ liệu đầu vào) và y (giá trị thực tế), đầu ra là trọng số sau khi "học".
- **Ý nghĩa của "Linear":** Tính "tuyến tính" ở đây là dành cho các tham số w, b , không phải dành cho đường vẽ hay dữ liệu đầu vào. Nghĩa là mô hình vẫn có thể học được các đường cong phức tạp (nếu ta biến đổi dữ liệu đầu vào thành đa thức), miễn là phương trình cấu thành nên mô hình là bậc 1 đối với các tham số.

II. Logistic Regression

1. Log Binary Loss và Quy tắc chuỗi (Chain Rule)

- **Tại sao dùng quy tắc chuỗi?** Mô hình logistic là một hàm hợp: dữ liệu qua hàm tuyến tính z , rồi qua hàm sigmoid để ra

xác suất y dự đoán, cuối cùng mới đưa vào hàm loss. Quy tắc chuỗi (Chain Rule) bắt buộc phải dùng để bóc tách từng lớp này khi lấy đạo hàm. => Thực chất chain rule là bước khá hay và là cơ sở cho khái niệm “backpropagation” cho deep learning sắp tới. Cơ bản nhất nó chính là việc ta có thể thay đổi cái lớn nhất thông qua cái nhỏ nhất. VD: để thay đổi loss function của logistic thì ta sẽ thay đổi trọng số w trong $z = Xw$ từ đó z sẽ ảnh hưởng tới hàm sigmoid và từ hàm sigmoid sẽ thay đổi đến hàm loss function của logistic -> có thể nói là “cha truyền con nối”

- **Tại sao phải chia nhỏ đến tham số?** Vì các tham số w , b là yếu tố duy nhất mô hình có thể điều chỉnh. Ta phải tính đạo hàm ngược về tận tham số để biết cần cộng trừ w , b bao nhiêu. -> XIN LƯU Ý RẰNG: thực chất đây là phương pháp chain rule, đồng thời w, b thực chất là 1. Nếu đúng chính xác thì b cũng là $w \times 1$ tức cũng là trọng số trong mô hình, nhưng vì đây là trọng số cuối không dính đến x hay nói đúng hơn là $x \times 1 = 1$.

2. "Kết quả đạo hàm là MSE"

- **"Kết quả của đạo hàm log loss và tại sao nó lại là MSE?"**. Đây là sự trùng hợp về đạo hàm của log loss, vì khi ta dùng chain rule, kết quả lại ra y hệt MSE, thực chất 2 function này ko giống nhau

3. Không gian Logit

- **Sự thay đổi output:** Thay vì xét output đã qua Sigmoid nằm trong khoảng $(0, 1)$. phương pháp này xét trực tiếp phương trình tuyến tính $z = wx + b$, khiến output có thể mang giá trị từ âm đến dương vô cùng

- Đồ thị và Ý nghĩa: Đồ thị của logistic trong không gian Logit (log-odds) bây giờ là một đường thẳng hoặc một mặt phẳng. Ý nghĩa của việc này là nó biến một bài toán phân loại với ranh giới cong (xác suất) thành một bài toán có ranh giới quyết định tuyến tính phẳng, giúp tối ưu hóa toán học một cách dễ dàng và mượt mà hơn.

4. Giá trị cốt lõi của Loss Function

- **Nếu ta chỉ dùng đạo hàm để cập nhật Gradient Descent, vậy hàm Loss để làm gì?** Hàm Loss đóng vai trò định nghĩa "mục tiêu", nó tạo ra hình dáng bề mặt không gian để đạo hàm có nơi hoạt động. Hơn nữa, con số thực tế mà hàm Loss trả về là tiêu chuẩn để con người theo dõi xem mô hình đang tiến bộ hay thụt lùi qua từng epoch.